

Claude Code KV- 캐시를 살려둘 가치가 있는가 ?

구독 과금 환경에서 cache-keepalive 플러그인 실측 A/B 검증

**결론 : 이 환경에서 플러그인은 절약이 없고 쿼터만 소모한다 —
캐시 TTL 이 1 시간이라 7 분 유희는 자체로 캐시가 유지되며 ,
모든 킵얼라이브 핑은 5 시간 쿼터를 깎는 불필요 요청이다 .
끄는 것을 권고한다 .**

세 가지 핵심 결론

이 환경의 캐시 TTL 은 5 분이 아니라 1 시간

- write 토큰 466,136 개 100% 가 ephemeral_1h 사용
- ephemeral_5m 사용량은 0 개
- 플러그인 전제 (300 초 TTL 격파) 가 성립하지 않음

7 분 유희 후에도 플러그인 없이 캐시는 따뜻함

- 7 분 4 개 암 모두 유희 직후 캐시 -read 우세 (35k~45k read)
- write 는 거의 0, 콜드 재작성 없음
- ON 암이 얻은 이득을 OFF 암도 공짜로 누림

킵얼라이브 핑 하나하나가 낭비된 구독 요청

- 구독 과금은 토큰이 아니라 요청 수로 청구
- 기본값은 유희당 최대 7 회 핑 발사 가능
- 토큰 이득 0 → 최대 7 개 요청 낭비

이 구독 설치 환경에서는 플러그인을 끈 채로 둘 것을 권고한다 .

플러그인은 비싼 캐시 write 를 값싼 캐시 read 로 바꾼다



동일 베이스라인, 실제 벽시계 유희로 구성된 5 개 라이브 암

워크로드 2 종 × 플러그인 ON/OFF + 70 분 TTL 탐침 암 1 종

A**wlA-off**

- 워크로드 A · TS API JSDoc
- 플러그인 OFF
- 7 분 유희

B**wlA-on**

- 워크로드 A · TS API JSDoc
- 플러그인 ON
- 7 분 유희

C**wlB-off**

- 워크로드 B · Python 오류경로
- 플러그인 OFF
- 7 분 유희

D**wlB-on**

- 워크로드 B · Python 오류경로
- 플러그인 ON
- 7 분 유희

E**ttl-long**

- TTL 한계 탐침
- 플러그인 OFF
- 70 분 단일 유희


각 암 = 일회용 워크트리 · n=1

7 분 유효는 따뜻하게 유지 , 70 분 유효만 콜드로 전환

유효 직후 첫 실행의 캐시 read vs write 토큰

캐시 토큰 , 천 토큰

■ 캐시 read ■ 캐시 write



핵심 시사점

- ttl-long 만 read 0 / write 25,134 — 완전 콜드 재작성
- 7 분 4 개 암은 read 우세 , 캐시 생존
- TTL 은 7~70 분 사이로 묶임 (문서상 1 시간과 일치)

약 150 톤 동안 5 분 캐시 write 는 단 한 건도 없었다

100%


ephemeral_1h 를 사용한 write 토큰 비중 (총 466,136 개)

ephemeral_5m write = 0 개 . 플러그인이 노리는 5 분 TTL 은 이 환경에 존재하지 않는다 .

따뜻한 암은 89~95%, 콜드 70 분 암만 56% 로 붕괴

캐시 히트율 (CHR) = $\text{read} / (\text{read} + \text{write})$

캐시 히트율, %



핵심 시사점

- wIA-on(90.4%) $\approx$ wIA-off(94.6%)
- ON·OFF 차이는 캐시 효과가 아닌 워크로드 노이즈
- 플러그인은 CHR 을 끌어올리지 못함
- 콜드 암만 유일하게 56% 로 급락

ON 암은 각각 값싼 킵얼라이브 read 1 회만 발사

wlA-on · t27 킵얼라이브 턴

- 캐시 read 35,691 토큰
- 캐시 write 25 토큰
- 출력 22 토큰 (0.1x 값싼 read)

wlB-on · t28 킵얼라이브 턴


- 캐시 read 44,355 토큰
- 캐시 write 909 토큰
- 출력 54 토큰 (0.1x 값싼 read)

5 분 TTL·API 과금이라면 유희당 약 41,000 가중 토큰 절약

약 36k 프리픽스 기준 유희당 가중 토큰

가중 토큰, 천 토큰

■ 가중 토큰



반사실 시나리오

- 콜드 재작성 $36k \times 1.25 \approx 45,000$
- 킵얼라이브 read $36k \times 0.10 \approx 3,600$
- 유희당 절약 약 41,400 — 단, +1 요청
- Aider·Cline 환경의 결과, 여기서 레버가 연결되지 않음

토큰 비용 (API) 은 거의 안 움직이고 , 요청 비용 (구독) 은 오르기만 한다

환경 · 유효 조건별 플러그인 판정

Criteria	플러그인 없음	플러그인 사용
이 환경 (1h TTL)·7 분 유효		
가상 5 분 TTL·7 분 유효		
이 환경 ·1 시간 초과 유효		

★ Recommended

여기선 플러그인을 끈 채로 — 과금·TTL 이 바뀔 때만 재검토

실행 : 이 구독 설치에서 **cache-keepalive** 비활성 유지

- 현재 1 시간 TTL 에서는 순수 오버헤드
- 유틸은 자체로 캐시를 따뜻하게 유지

재검토 트리거 : API- 키 과금 전환 + 전사에 **ephemeral_5m write** 관측

- 두 조건이 동시에 성립할 때만 유효
- TTL 은 계약이 아닌 환경 변수 (1h→5m, 2026/3 변경 전례)

조치 : 조건 충족 시 **harness/run-all.py** 재실행

- S6 반사실 분석이 실제 API 비용 절감을 예측

현 환경 권고 : 플러그인 **OFF** 유지 . 과금 또는 TTL 변경 시에만 재검토 .

방법론 견고성과 한계

견고한 근거

- ✓ 유희 경계 캐시 상태는 턴 수에 무관하게 robust
- ✓ CHR 도 턴 수 영향 없이 robust
- ✓ 70 분 단일 유희 암이 TTL 을 7~70 분으로 고정

한계 및 주의

- ✗ 암당 $n=1$
- ✗ Claude 비결정성으로 암 간 총량 교란 (45 vs 35 턴)
- ✗ TTL 을 분 단위로 정확히 특정하지 못함